

Práctica M54 - Cloud Analytics & Data Lake

Autor: Patrick

1. Configuración de un Data Lake Simple

La arquitectura del Data Lake se ha conceptualizado empleando **Amazon S3** para asegurar escalabilidad y separación de entornos.

- **Capa Raw (Bronce):** Se establece un bucket inicial (ej. `s3://datalake-raw-zone`) que actúa como punto de aterrizaje para el archivo `Analista de datos M54 - kc_house_data.csv` en su formato original, sin transformaciones.
- **Capa Processed (Plata):** Mediante procesos ETL, se extraen los datos raw, se limpian (sanitización de columnas, tratamiento de nulos) y se almacenan en formato Parquet dentro de un bucket procesado (ej. `s3://datalake-processed-zone`), asegurando codificación UTF-8.
- **Capa Curated (Oro):** Datos refinados, agregados y listos para su consumo en reportes o análisis de negocio directo.

2. Configuración de una Base de Datos en la Nube

Para habilitar el acceso estructurado a la información, se provisiona una base de datos relacional orientada a la explotación analítica de la capa procesada.

- **Servicio Seleccionado:** Instancia de **Amazon RDS con PostgreSQL**.
- **Estructuración:** Se genera una base de datos empleando el patrón `IF EXISTS ... DROP DATABASE` seguido de `CREATE DATABASE`.
- **Organización de Esquemas:** Se implementan esquemas lógicos para aislar las tablas de negocio.

```
CREATE SCHEMA housing_analytics;
```

3. Conexión e Importación del Archivo de Housing

El flujo en Python lee el archivo fuente local y transfiere los datos a la infraestructura en la nube utilizando el conector SQLAlchemy.

```
import pandas as pd
from sqlalchemy import create_engine
import os

# Carga el archivo
ruta_archivo = os.path.join(r'C:\Users\patri\Downloads', 'Analista de datos
M54 - kc_house_data.csv')
df = pd.read_csv(ruta_archivo, encoding='utf-8')

# Conexión a la base de datos cloud (RDS PostgreSQL)
engine = create_engine('postgresql://usuario:password@endpoint-
rds.amazonaws.com:5432/housing_db')

# Transfiere la estructura a la nube
df.to_sql('kc_house', con=engine, schema='housing_analytics',
if_exists='replace', index=False)
```

Una vez concluida esta etapa, la tabla queda disponible en el esquema `housing_analytics` y preparada para el posterior análisis exploratorio mediante queries o dashboards.